

Линейная Классификация

$\mathbb{Y} = \{1, \dots, k\}$ = многоклассовая классификация

$$\mathbb{Y} = \left\{ \begin{array}{cc} \underline{-1} & , \quad \underline{+1} \\ \text{отриц классиф.} & \text{отриц класс} \end{array} \right\} - \text{бинарная классификация}$$

$$\alpha(x) := \text{sign} \langle w, x \rangle$$

Что делать если $\langle w, x \rangle = 0$?

1. фиксированный класс выдавать
2. случайный класс
3. сказать что такого не бывает
4. отказ от классификации

$$\alpha(x) := \text{sign} (\langle w, x \rangle - t), \quad t - \text{giperparameter}$$

Знаем:

$\langle w, x \rangle$ — условие ортогональности, и является уравнением гиперплоскости, w — вектор нормали

there should be a reminder from linear algebra here, a graph and stuff (add later)

Обучение

Запишем функцинал:

$$Q(\alpha, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [\alpha(x_i) \neq y_i] - \text{доля ошибок (error rate)}$$

Проблема тут что производная либо 0 либо отсутствует.

$$\frac{1}{\ell} \sum_{i=1}^{\ell} [\text{sign} \langle w, x_i \rangle \neq y_i] = \frac{1}{\ell} \sum_{i=1}^{\ell} \left[\frac{y_i \langle w, x_i \rangle}{M_i} < 0 \right] \rightarrow \min_w$$

Margin.

$$M_i = y_i \langle w, x_i \rangle - \text{отступ (margin)}$$

Где sign M говорит о корретности классификации, и |M| говорит об уверенности модели.

Пока что наша функция потерь:

$$L(M) = [M < 0] - \text{пороговая ф.п.}$$

make a graph a bit later here

Идея:

$$[\mu < 0] \leq L^\vee(\mu) - \text{дифф верная оценка}$$

$$0 \leq \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \langle w, x_i \rangle < 0] \leq \frac{1}{\ell} \sum_{i=1}^{\ell} L^\vee(y_i \langle w, x_i \rangle) \rightarrow \min_w$$

Можно попробовать по подбирать разные:

1. $L_1^\vee(\mu) = \log(1 + \exp(-\mu))$ log ф.п
2. $L_2^\vee(\mu) = \max(0, 1 - \mu)$ hinge loss

$$3. L_3^\sim(\mu) = \frac{\arctan(-\mu)}{\pi} + 1$$

Далее будем рассматривать как выбирать между верхней оценки, но пока просто представим что мы некую выбрали.

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L^\sim(y_i \langle w, x_i \rangle) + \alpha R(w) \rightarrow \min_w$$

Метрики качества классификации

Доля верных ответов. (Accuracy)

$$\frac{1}{\ell} \sum_{i=1}^{\ell} [\alpha(x_i) = y_i]$$

Какая тут есть проблема?

Дизбаланс классов.

class sign	num	res
+1 :	50	$\alpha(x) = -1$
-1 :	950	accuracy = 0.95

Мораль: Когда работаете с задачей классификации всегда необходимо смотреть на баланс классов.

Далее, когда мы улучшаем модель, есть два способа измерения прироста:

1. $|r_1 - r_2|$
2. $|r_1 - r_2| r_1$

Рассмотрим пример:

r_1, r_2	abs	rel
20%, 10%	10%	50%
50%, 25%	25%	50%
0.1%, 0.01%	0.09%	90%