

Лекция 1. Основные понятия

Объект $x :=$ то что мы анализируем.

Пространство объектов $\mathbb{X} :=$ множество объектов.

Целевая переменная $y :=$ то что мы пытаемся найти.

Пространство целевых переменных $\mathbb{Y} :=$ множество целевых переменных.

Обучающая выборка $X := (x_i, y_i)_i, |X| = \ell$

Признаки $X_i = (x_{i1}, \dots, x_{id}), d = |X_i|$. Признаки X_i могут быть:

1. Числовыми. $x_j \in \mathbb{R}$
2. Категориальными. $x_j \in \{C_1, \dots, C_m\}$ где есть только операции сравнения и тождество.
3. Упорядочные. $x_j \in \{C_1, \dots, C_m\}$ где есть только операция упорядочения.

Типы задач в машинном обучении. Задачи определяются целевой переменной.

I. Supervised Learning. Дана обучающая выборка $X_i = (x_i, y_i)_i$ с правильными ответами.

1. Линейная регрессия. $\mathbb{Y} = \mathbb{R}$
2. Классификация. $|\mathbb{Y}| < \infty$.
 - $\mathbb{Y} = \{0, 1\}$ (binary)
 - $\mathbb{Y} = \{1, \dots, k\}$ (multiclass)
 - $\mathbb{Y} = \{0, 1\}^k$ (multilabel)
3. Ранжирование.

II. Unsupervised Learning. Дана обучающая выборка $X_i = (x_i, y_i)_i$ без правильных ответов.

1. Кластеризация.
2. Поиск аномалий через оценивания плотности.

III. Partial Learning.

Модель. $\mathcal{A}$

$\alpha : \mathbb{X} \rightarrow \mathbb{Y} \quad s.t. \quad \alpha(x) \approx y$

1. Дифференцируемые модели.
2. Недифференцируемые модели.

Функция потерь. (Loss function)

$$L : \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}^+, \text{ как пример } L : (y, a)'n = (y - a)^2$$

Функционал ошибки. (Cost function)

$$Q(\alpha, X) = \frac{1}{\ell} \cdot \sum_{i=1}^{\ell} v_i \cdot L(y_i, \alpha(x_i))$$

Обучение модели.

$$Q(\alpha, X) \longrightarrow \min_{\alpha \in \mathcal{A}}$$

Лекция 2. Модель линейной регрессии.

Пусть $\mathbb{Y} = \mathbb{R}^+$, $\mathbb{X} = \mathbb{R}^d$, $X_i := (x_{i1}, \dots, x_{id})$

$$\alpha(x) = \underbrace{w_0}_{\text{bias}} + \left(\sum_{j=1}^d \underbrace{w_j}_{\text{weights}} \overbrace{x_j}^{\text{feature}} \right)$$

или; свободная переменная, веса, и признаки.

Данную модель можно переписать как:

$$\alpha(x) = w_0 + \langle \vec{w}, \vec{x} \rangle$$

В модели линейной регрессии необходимо чтобы каждый признак влияет линейно на целевую переменную, это происходит редко, а значит что нужно работать с данными.

Изменение ошибки в задачах модели линейной регрессии.

Рассмотрим форматы оценки отклонение функции потерь $L(a, y)$.

MSE (Mean squared error).

$$L(y, a) = (y - a)^2$$
$$\text{MSE}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

RMSE (Root mean squared error).

$$\text{RMSE}(a, X) = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2}$$

Коэффициент детерминации (Коэффициент R^2)

•

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^{\ell} (a(x_i) - y_i)^2}{\sum_{i=1}^{\ell} (y_i - \bar{y})^2}$$

Коэффициент детерминации (R^2), грубо говоря, показывает нормированную среднеквадратическую ошибку.

MAE (Mean absolute error).

Происходит если заменить функцию потерь $L(y, a) = |a - y|$ на модуль.

$$\text{MAE}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} |a(x_i) - y_i|$$

MAE лучше MSE в случаях когда нет необходимости приувеличивать эффект больших ошибок, когда MSE лучше когда необходимо более строго наказывать большие ошибки.

RMSE стоит использовать когда единицы измерения нужно сохранять, и возведение в квадрата приносит проблемы.

Коэффициент R^2 показывает как хорошо модель предсказывает. Если она близка к единице, то модель хорошо объясняет данные, если же она близка к нулю, то прогнозы сопоставимы по качеству с константным предсказанием.

Лекция 3. Линейная регрессия: Переобучение и обучение.

Переобучение

Модель переобучена когда её качество на новых данных существенно хуже качества на обучающей выборке.

Норма вектора коэффициентов $\{x, x^2, \dots, x^n\}$ используется как величина которая штрафует для контроля сложности модели, что называется регуляризацией.

Кросс-валидация

Размеченные данные разбиваются на k -блоков $X_1, \dots, X_k$ примерно одного размера. Далее обучаются k моделей $a_1(x), \dots, a_k(x)$, где i -я модель обучается на объектах u из всех блоков, кроме блока i . После этого качество модели можно оценить по тому блоку на которой она не обучалась. После этого результат усредняется.

$$CV = \frac{1}{k} \sum_{i=1}^k Q(a_{i(x)}, X_i)$$

Обучение модели линейной регрессии.

Если модель обучается с использованием MSE, то мы получаем задачу оптимизации.

$$\frac{1}{\ell} \sum_i^t = 1(\langle \vec{w}, x_i \rangle - y_i)^2 \rightarrow \min_w$$

которую можно переписать в матричном виде.

$$\frac{1}{\ell} \|Xwy\|^2 \rightarrow \min_w$$

Теоретическое домашнее задание №1.

Задача 1.

Модель:

$$y_i = wx_i$$

Обозначим:

$$S_{xx} = \sum_{i=1}^t x_i^2, \quad S_{xy} = \sum_{i=1}^t x_i y_i$$

Линейная регрессия без штрафа:

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^d (y_i - wx_i)^2 \Rightarrow \frac{\delta Q}{\delta w} = \frac{2}{\ell} \sum_{i=1}^d (-x_i)(y_i - wx_i) = -\frac{2}{\ell} (S_{xy} - wS_{xx})$$

$$S_{xy} - wS_{xx} = 0 \Rightarrow w^* = \frac{S_{xy}}{S_{xx}}$$

Ridge-regression:

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^d (y_i - wx_i)^2 + \lambda w^2 \Rightarrow -\frac{2}{\ell} (S_{xy} - wS_{xx}) + \lambda w$$

$$\left(\text{Умножим на } \frac{\ell}{2} \right) := -(S_{xy} - wS_{xx}) + \lambda w\ell = 0$$

$$S_{xy} = w(S_{xx} + \lambda\ell) \Rightarrow w = \frac{S_{xy}}{S_{xx} + \lambda\ell}$$

Lasso-regression:

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^d (y_i - wx_i)^2 + \lambda |w|$$

Нужно рассмотреть $w > 0, w < 0$.

$$(w > 0)$$

$$-\frac{2}{\ell} (S_{xy} - wS_{xx}) + \lambda = 0$$

$$S_{xy} = wS_{xx} + \frac{\lambda\ell}{2} \Rightarrow w = \frac{S_{xy} - \frac{\lambda\ell}{2}}{S_{xx}}$$

$$(w < 0)$$

$$w = \frac{S_{xy} + \frac{\lambda\ell}{2}}{S_{xx}}$$

Рассмотрим пределы:

Ridge:

$$w = \frac{S_{xy}}{S_{xx} + \lambda\ell} \Rightarrow w \xrightarrow{\lambda \rightarrow 0} \frac{S_{xy}}{S_{xx}}, \quad w \xrightarrow{\lambda \rightarrow \infty} 0$$

Lasso:

$$w = \frac{S_{xy} \pm \frac{\lambda\ell}{2}}{S_{xx}} \Rightarrow w \xrightarrow{\lambda \rightarrow 0} \frac{S_{xy}}{S_{xx}}, \quad w \xrightarrow{\lambda \rightarrow \infty} 0$$

Мы считаем что λ это сила штрафа за сложность модели.

△

Задача 2.

Целевая функция:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - w)^2 + \lambda w^2$$

Дано что $\ell = 3, y_1 = 6, y_2 = 6, y_3 = 10 \Rightarrow \bar{y} = \frac{22}{3}$

Найдем оптимальный w при произвольном λ .

$$-\frac{2}{3} \sum_{i=1}^{\ell} (y_i - w) + 2\lambda w = 0 \Rightarrow \sum_{i=1}^{\ell} y_i - 3w = 3\lambda w$$

Задача 3.

1. Что такое гиперпараметр модели и чем он отличается от параметра модели?

Параметр модели это значения которые обучаются на данных. Как пример это коэффициенты линейной регрессии.

$$\alpha(x) = w_0 + \sum_{i=1}^d w_i x_i$$

Гиперпараметры это настройки модели которые задаются извне до обучения и не оптимизируются напрямую на обучающей выборке $X_i := (x_i, y_i)_i$.

2. Почему коэффициент регуляризации нельзя подбирать по обучающей выборке? Как подобрать оптимальное значение для коэффициента регуляризации?

Если подбирать коэффициент регуляризации по обучающей выборке X то модель будет подгоняться под нее, игнорируя возможность обобщения, и риск переобучения более высок.

Чтобы подобрать оптимальный коэффициент регуляризации необходимо использовать кросс-валидацию. Кросс-валидация предполагает следующее:

- Делим данные на k блоков $X_1, \dots, X_K$ одного размера.
- k моделей обучаются $a_1(x), \dots, a_{k(x)}$ где i -ая модель обучается на объектах y из всех блоков кроме блока i .
- Оцениванием качество модели по тому блоку по которому она не обучалась и усредняется результат.

4. Почему накладывать регуляризатор на свободный коэффициент w_0 может быть плохой идеей?

Свободный коэффициент отвечает за сдвиг модели, и никак не связан со сложностью модели, просто центрируя ее. Если его штрафовать то модель может сместиться, нарушив интерпретацию.

5. Что такое кросс-валидация, чем она лучше использования отложенной выборки?

Кросс-валидация метод подбора оптимального коэффициента регуляризации. Он состоит из следующих шагов:

1. Размеченные данные делим на k частей $X_1, \dots, X_k$ примерно одного размера.
2. k моделей обучаются на $a_1(x), \dots, a_{k(x)}$, где i -ая модель обучается на объектах из всех блоков кроме i .
3. Оцениваем качество модели по тому блоку по которому она не обучалась и усредняется результат.
6. Почему категориальные признаки нельзя закодировать натуральными числами? Что такое one-hot encoding?

Потому что если закодировать green = 1, red = 2, blue = 3, то модель будет считать что blue > red > green, т.е. некоторый порядок между ними.

One-Hot encoding процесс в котором каждой категории мы выдаем бинарный признак. Это значит что все отдельные признаки либо 1 либо 0.

7. Для чего нужно масштабировать матрицу объекты-признаки перед обучением моделей машинного обучения?

Регуляризация зависит от масштаба т.к. если один признак в метрах а другой в миллиметрах то штраф будет разный и веса несопоставимы.

8. Почему L1-регуляризация производит отбор признаков?

$$\text{L1 штраф} := \lambda \sum_{i=1}^d |w_i|$$

Оно имеет острый угол в нуле и оптимизация часто приводит веса ровно к нулю.

9. Почему MSE чувствительно к выбросам?

$$\text{MSE}(a, X) = \frac{1}{\ell} \sum_{i=1}^t (a(x_i) - y_i)^2$$

Можно заметить что ошибка чувствительная к выбросам, а значит что выбросы будут иметь квадратично растущий вклад, они доминируют в функции потерь.

△