

Теория вероятности и математическая статистика

Лекция 6

Лемма Фишера и введение в математическую статистику

Экономика и анализ данных

Фрейре Серёгина Даниэль Фабиан

О любых найденных ошибках, несостыковках, и опечатках сообщать мне, либи сделать merge request на гит. Я буду очень благодарен.

Лемма Фишера

$$\text{Пусть } \exists Z = \begin{pmatrix} z_1 \\ \dots \\ z_n \end{pmatrix} \sim N(0, I), \quad C - \text{ортогональна}, Y = CZ$$

$$\text{Тогда } T = \sum_{i=1}^n z_i^2 - Y_1^2 - \dots - Y_k^2 \sim \chi_{n-k}^2, \quad T \text{ и } Y_1, \dots, Y_k \text{ независимы}$$

□

$$Y = CZ \sim N$$

$$\mathbb{E}(Y) = \mathbb{E}(CZ) = C\mathbb{E}(Z) = C \cdot 0 = 0, \quad \text{cov}(Y) = \text{cov}(CZ) = C \text{cov}(Z) \underbrace{C^T}_{C^{-1}} = CC^T = I$$

$$(1) := \sum_{i=1}^n z_i^2 = \|Z\|^2 = (Z^T \cdot Z)$$

$$(2) := \sum_{i=1}^n Y_i^2 = \|Y\|^2 = (Y^T \cdot Y) = ((CZ)^T \cdot (CZ)) = \left(Z^T \underbrace{C^T C}_I Z \right) = (Z^T Z)$$

$$(1) \& (2) \Rightarrow \sum_{i=1}^n z_i^2 = \|Z\|^2 = (Z^T \cdot Z) = \sum_{i=1}^n Y_i^2$$

$$\text{В итоге: } T = \sum_{i=1}^n z_i^2 - Y_1^2 - \dots - Y_k^2 = \underbrace{Y_{k+1}^2 + \dots + Y_n^2}_{\sim \chi_{n-k}^2} \text{ не зависят от } Y_1 \dots Y_k$$

■

Математическая статистика.

Математическая статистика решает обратные задачи задачам теории вероятности.

Совместная работа:

$$\text{Данные} \xrightarrow[\text{матстат}]{} \text{Распределение} \xrightarrow[\text{тервер}]{} \text{Вероятность}$$

Генеральная совокупность (понятие)

Генеральная совокупность — это совокупность всех мыслимых наблюдений, которые могли быть наблюдаемы. Считается, что она ненаблюдаема.

Примеры:

Рассмотрим рост, тогда генеральная совокупность — это рост всех людей на планете Земля.

Реализация выборки

Каждая реализация может быть другой, поэтому мы должны собрать такую выборку, чтобы

Выборка (1)

Часть генеральной совокупности, по которой мы будем делать выводы о генеральной совокупности. Она должна хорошо представлять генеральную совокупность.

Формальнее:

Выборка — это последовательность с.в. $X_1, \dots, X_n \sim \text{iid}$ из распределения $F(x)$, где функция $F(x) = P(X_1 \leq x)$, где $x_1, \dots, x_n$ — это реализации (конкретные значения).

Выборка (2) Выборка — это n независимых наблюдений над с.в. X с функцией распределения $F(x)$.

Способы организации выборки.

1. Простой случайный отбор.
2. Простой отбор с помощью регулярной, но не существенной для изучаемого признака процедуры.
3. Стратифицированный отбор. (Часто бывает такое, что отдельные части выборки неоднородны. Как пример для ресторанов: для средних ценников ресторанов нужно наблюдать ценники из разных ресторанов, разбить стоит их по категориям.)
4. Серийный отбор.
5. Комбинированный..

Основные характеристики выборки.

1. Вариационный ряд.

$X_1, \dots, X_n \sim F(x), \Rightarrow \underbrace{X_{(1)}}_{\text{min value}}, \leq X_{(2)} \leq \dots \leq X_{(n)},$ где $X_{(1)}, X_{(n)}$ экстремальные статистики